



Vincent Xing

AAAI-Fable / M2NA 项目

2026 年 6 月 30 日

任务定义

M2NA: Mechanism-to-Narrative Analogy Generation。目标是把机制型概念转成短小、隐含、可解释的叙事类比。

输入

- 目标概念 c
- 机制图 $G_c = (V_c, E_c)$
- 禁用词集合 T_c

输出

- 隐性短叙事 N
- 节点对齐 A_V
- 边/关系对齐 A_E

核心约束：机制保持、词汇隐藏、结构可对齐、叙事最小性。

直接让模型“写一个寓言/类比”会带来三个问题：

- ❶ 知识来源不清楚：故事可能合理，但机制事实没有 grounding。
- ❷ 只覆盖关键词：模型容易提到概念相关实体，却漏掉因果边或方向。
- ❸ 评估难落地：没有显式机制图和映射，无法计算节点/边覆盖。

Graph RAG 在这里的角色

从课程知识图谱中检索结构化证据，把“概念解释”拆成可验证的机制节点、关系和来源 ID，再进入生成阶段。

方向	代表工作	对本项目的启发
叙事类比	ARN, TACL 2024; Curious Case, AAIL 2026	类比成功依赖 system / relational mapping, 而不是表面相似。
科学类比教学	Scientific Concept Analogy, EMNLP 2024; LLM analogy tutoring	类比可以服务概念理解, 但需要控制准确性和教学有效性。
Graph-to-Text	Graph-to-Text with LLMs, NAACL 2025	复杂图到文本的瓶颈在规划和归因, 不只是 prompt。
隐性映射	Metaphoric Analogy, COLING 2025	隐含元素和结构化映射可以被抽取、标注和评估。


- 结构对齐是主轴：节点覆盖和边覆盖必须分开报告。
- 先规划、后生成：机制图提炼和叙事生成不能混成一个黑盒 prompt。
- **hard negative** 必须有：只看主题相似会高估模型能力，需要方向反转、关系遗漏等负例。
- 叙事质量单独评估：故事自然不等于机制正确；机制正确也不等于故事好。
- 教育价值是后续主实验：当前先把自动结构评估和最小闭环跑通。

我重点负责

Graph RAG / 生成流水线 / 自动评测闭环。

已经落地的部分：

- 从 K12-KGraph 富属性图中定位概念并检索证据子图。
- 将检索证据序列化给模型，区分原始边、机制路径和高层摘要。
- 两阶段生成：机制图提炼 → 隐性叙事与结构映射。
- 自动评测：格式、泄露、节点覆盖、边覆盖、映射精确率、方向准确率。
- 批量脚本：支持多概念、多检索模式对比，并保留失败原因。



原始 KG 边
路径证据
高层摘要

正文不泄露概念词
但必须可映射回机制

输出文件: 01_retrieved_subgraph.json、02_mechanism_graph.json
03_generation.jsonl、04_metrics.json

one_hop: 局部邻域 baseline

做法：只取目标概念的一跳关系边。

价值：上下文短、噪声少，适合做最小可控对照。

dual_level: LightRAG 风格

做法：同时提供低层原始边和高层主题摘要。

价值：让模型既看到证据细节，也看到全局结构。

path_pruned: PathRAG 风格

做法：先扩展 1-2 hop 候选路径，再裁剪出机制相关路径。


价值：比一跳更容易捕捉“条件 → 过程 → 结果”链条。

path_dual: 路径 + 双层上下文

做法：在路径裁剪基础上补充高层摘要。

价值：信息最完整，适合正式生成，但上下文更长。

共同原则：原始 KG 边、裁剪路径和高层摘要分层保存；只有带来源 ID 的原始边可作为 grounding。



为什么需要

- 一跳边可能只给定义或分类。
- 机制概念常需要多步关系链。

如何控制噪声

- 限制 hop、路径数和边数。
- 优先保留机制关系和教材证据。

给生成的作用

- 明确“先后/因果”顺序。
- 降低只复述散点知识的风险。

低层: raw_edges

- 来自 K12-KGraph 的原始关系边。
- 保留 source/target、relation、evidence 和来源 ID。
- 用于机制图 grounding 和后续可追溯检查。

高层: topic_summary

- 根据检索结果生成规则化主题摘要。
- 帮助模型把零散边组织成“条件、过程、结果”。
- 只作为背景，不替代原始 KG 事实。

组合策略: path_dual

先用 path_pruned 选择机制路径，再补充 topic_summary 给全局语义。它更适合复杂概念，但也带来更长上下文和更高验证压力。

排版到 prompt 时三类上下文明确分区: raw_edges / selected_paths / topic_summary。

运行链路

- 学科：biology
- 概念：光合作用
- 后端：fixture / DeepSeek
- 输出：检索子图、机制图、叙事、指标

这个样例没有直接说出目标概念和高泄露术语，但保留了“光驱动、输入物、产物、能量储存、生态作用”的机制链。

隐性叙事片段

海边工坊每天打开屋顶的绿色薄板，让晨光驱动机器。两条管道分别送来井水和空气中的一种废气，车间把它们合成耐储存的糖砖

.....

指标	检查内容
format validity	生成记录是否符合 schema 和映射结构要求。
node coverage	叙事是否覆盖机制图关键节点。
edge coverage	叙事是否覆盖机制图关键关系。
alignment precision	映射是否指向真实存在的叙事元素。
direction accuracy	边的 source/target 方向是否保持。
concept / soft leakage	是否泄露概念名或高提示性术语。
template hit rate	是否命中高频模板意象或套路。

修复后的评测器不依赖模型自报的 `direction_preserved`，而是根据映射 `source/target` 独立计算方向。

指标	数值
format validity	1.0
node coverage	1.0
edge coverage	1.0
alignment precision	1.0
direction accuracy	1.0
exact leakage	0.0
soft leakage	0.0
template hit rate	0.0

解读

- 单样例 fixture 不证明泛化能力。
- 它证明了端到端接口、文件产物和评测闭环是可执行的。
- 适合作为回归测试和组会 demo。

检索模式	OK	Failed
one_hop	7	3
path_pruned	9	1
dual_level	9	1
path_dual	8	2
Total	33	7

通过样本上的平均指标

- 四种模式的节点/边覆盖、映射精确率、方向准确率均为 1.0。
- 精确概念泄露和软术语泄露均为 0.0。
- 优化前通过 25/40；加入方向合同和两轮修复后提升到 33/40。
- 本轮没有出现方向反转失败，剩余问题集中在长度和 anchor。

注意：这里的 1.0 是通过验证样本的均值，不代表失败样本也合格。

- **anchor 不在正文**：模型给出映射，但对应叙事片段并不存在。
- **长度违规**：模型倾向生成过短物理类故事，不满足 90–260 字约束。
- **方向反转失败已消除**：本轮失败中没有 source/target 反向错误。

这对研究是有用的

优化后的主要瓶颈从“方向保持”转移到“锚点可验证”和“叙事长度控制”，下一步应做 anchor-first 生成或本地自动补锚。

不足	当前表现	风险
样本规模小	pilot 级别，fixture 单样例可稳定复现	只能证明闭环可跑，不能证明方法泛化。
生成稳定性不足	优化后通过率 33/40；剩余 anchor 缺失和长度违规	模型能写故事，但仍不稳定遵守可验证输出约束。
自动评测需校准	目前主要依赖规则和结构化映射检查	需要证明自动指标和人工判断一致。
叙事质量评估浅	重点检查结构、泄露和映射	还不能充分说明故事是否自然、有转折、少模板。
教育效果未验证	尚未做人类学习实验	只能说“生成合格”，还不能说“帮助学习”。

结论

下一步不是单纯多跑样本，而是把失败类型转化为可验证的工程约束和评估设计。

1. 扩大概念集

- 先扩到 20-50 个机制型概念。
- 覆盖 biology / physics。
- 每个概念保留 KG 来源和机制图版本。

2. 提高生成稳定性

- 已加入机制边方向合同。
- 提示模型先自检 anchor 再输出。
- 验证失败后最多两轮定向 retry。

3. 强化结构自检

- 检查 anchor 是否真实出现在正文。
- 逐边验证 source/target 方向。
- 针对长度、泄露、缺失映射给出修复反馈。

具体改动目标

本轮已把“生成后发现错误”推进到“生成时有方向合同、失败后可定位修复”。

人工/专家评估接入

- 样本级评分：Faithfulness、Alignment、Concealment、Narrative Quality、Pedagogical Usefulness。
- 节点映射：existence / correctness / specificity。
- 边映射：relation correctness / direction correctness。
- 错误标签：missing edge、reversed causality、theme-only analogy、template story。

下一轮实验设计

- 构造 hard negatives：surface distractor、relation corruption、mechanism omission。
- 对比 baseline：Direct Narrative、RAG-only、Alignment-then-Write、Full M2NA。
- 报告自动指标与人工评分相关性。
- 小规模学习实验验证 understanding / transfer / retention。

汇报结论

当前已经完成 Graph RAG 到 M2NA 自动评测的最小闭环；下一阶段重点是提高生成稳定性，并把自动评测、人工评估和学习效果串起来。